

GİRİŞ

Son yıllarda derin öğrenme teknikleri, görüntü işleme alanında önemli başarılar elde etmiş ve çeşitli sınıflandırma problemlerinde üstün performans göstermiştir. Özellikle, konvolüsyonel sinir ağları (CNN), büyük veri kümeleri üzerinde eğitildiğinde, insan düzeyine yakın veya daha iyi sonuçlar elde edebilmektedir (Krizhevsky et al., 2012). Hayvan sınıflandırması, biyolojik çeşitliliğin korunması, tarımsal uygulamalar, yaban hayatı izleme ve veterinerlik gibi birçok alanda önemli bir rol oynamaktadır. Geleneksel yöntemler, elle mühendislik gerektiren özellik çıkarmaya dayanırken, derin öğrenme tabanlı yaklaşımlar veriden otomatik olarak öğrenme yeteneği ile daha yüksek doğruluk oranları sağlamaktadır.

Örneğin, Krizhevsky ve arkadaşları (2012) tarafından geliştirilen AlexNet modeli, ImageNet veri kümesinde 1.2 milyon yüksek çözünürlüklü görüntü üzerinde eğitilmiş ve top-5 hata oranını %26.2'den %15.3'e düşürerek o dönemin en başarılı modellerinden biri olmuştur. Bu gelişmeler, hayvan türlerini sınıflandırmaya yönelik çalışmalar için de yeni fırsatlar sunmaktadır.

Bu çalışmada, derin öğrenme tabanlı hayvan sınıflandırma sistemlerinin performansını değerlendirmek için mevcut literatür incelenmiş ve en iyi yöntemler belirlenmiştir. Çalışma, farklı CNN tabanlı modellerin doğruluk oranlarını karşılaştırarak, hayvan sınıflandırmasında en etkili yöntemleri belirlemeyi amaçlamaktadır.

LİTERATÜR TARAMASI

Hayvan sınıflandırması, bilgisayarla görü ve makine öğrenmesi alanında uzun süredir incelenen konular arasında yer almaktadır. İlk çalışmalar, görüntülerden elle seçilen özellikler çıkararak geleneksel makine öğrenmesi algoritmalarıyla sınıflandırma yapmaya odaklanmış olsa da, derin öğrenme yöntemlerinin gelişimiyle birlikte bu alanda önemli ilerlemeler kaydedilmiştir.

Krizhevsky ve arkadaşları (2012) tarafından geliştirilen AlexNet modeli, derin öğrenme tabanlı sınıflandırma sistemlerinin gücünü gösteren ilk çalışmalardan biridir. ImageNet veri kümesi üzerinde yapılan deneylerde, geleneksel yöntemlere kıyasla önemli bir hata oranı düşüşü sağlanmıştır. Model, beş konvolüsyonel ve üç tam bağlı katmandan oluşan mimarisiyle %15.3 top-5 hata oranı elde ederek sınıflandırma problemlerinde devrim yaratmıştır.

Daha sonra geliştirilen VGGNet (Simonyan & Zisserman, 2014) ve GoogleNet (Szegedy et al., 2015) modelleri, daha derin katmanlarla daha iyi genelleme yetenekleri sunarak sınıflandırma doğruluğunu artırmıştır. Özellikle, He ve arkadaşları (2016) tarafından önerilen Residual Networks (ResNet), 152 katmanlı mimarisi ile ImageNet üzerinde %3.57 top-5 hata oranı yakalamış ve derin öğrenme modellerinin daha derin mimarilerle daha iyi performans gösterebileceğini kanıtlamıştır.

Hayvan sınıflandırması özelinde, Litjens ve arkadaşları (2017), transfer öğrenme kullanarak tıbbi görüntü analizi alanında derin öğrenme modellerinin başarısını değerlendirmiştir. Transfer öğrenme tekniği, önceden eğitilmiş büyük ölçekli modellerin, daha küçük veri kümelerine sahip özel alanlara adapte edilmesini sağlayarak sınıflandırma doğruluğunu artırmaktadır.

Son yıllarda, kapsül ağlar (CapsNet) gibi yeni yöntemler, CNN'lerin sınırlamalarını aşmaya yönelik olarak önerilmiştir (Sabour et al., 2017). Bu yöntemler, özellikle benzer görünüme sahip türlerin sınıflandırılması gibi zorlu görevlerde daha başarılı sonuçlar elde etmeyi amaçlamaktadır.

Genel olarak, derin öğrenme tabanlı hayvan sınıflandırma sistemleri, geleneksel yöntemlere kıyasla büyük veri kümeleri üzerinde eğitildiğinde çok daha yüksek doğruluk oranları sağlamaktadır. Ancak, veri miktarının artırılması, etiketleme süreçlerinin iyileştirilmesi ve model genelleme yeteneklerinin geliştirilmesi gibi konular, bu alandaki araştırmalar için hala önemli zorluklar arasında yer almaktadır.

KAYNAKÇA

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 770-778. [<https://ieeexplore.ieee.org/document/7780459>]

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in neural information processing systems, 25. [<https://dl.acm.org/doi/10.1145/3065386>]

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... & van der Laak, J. A. W. M. (2017). A survey on deep learning in medical image analysis. Medical image analysis, 42, 60-88. [<https://www.sciencedirect.com/science/article/abs/pii/S1361841517301135?via%3Dihub>]

Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. IEEE Transactions on knowledge and data engineering, 22(10), 1345-1359. [<https://ieeexplore.ieee.org/document/5288526>]

Sabour, S., Frosst, N., & Hinton, G. E. (2017). Dynamic routing between capsules. Advances in neural information processing systems, 30. [<https://arxiv.org/abs/1710.09829>]

Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv:1409.1556. [<https://arxiv.org/abs/1409.1556>]

Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., ... & Rabinovich, A. (2015). Going deeper with convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 1-9. [<https://ieeexplore.ieee.org/document/7298594>]